Linguaggi di Programmazione

Capitolo 2 – Grammatiche e Linguaggi



Linguaggi formali e monoidi liberi

Il concetto di linguaggio formale è strettamente correlato a quello di monoide libero (generato da un insieme).



Definizione di Alfabeto

- Un insieme X finito e non vuoto di simboli è un alfabeto.
- Esempi
 - □ L'alfabeto latino, con l'aggiunta dei simboli di interpunzione e dello spazio bianco: a b c ...z;,.:
 - L'insieme delle dieci cifre arabe: 0 1 ... 9
- Con i simboli primitivi dell'alfabeto si formano le parole (es.: abc, 127, casa,...).



Definizione di Parola o Stringa

- Una sequenza finita di simboli $x_1x_2...x_n$, dove ogni x_i è preso da uno stesso alfabeto X è una parola (su X).
- Esempio

 - 001110 è una parola su X
- Una parola è ottenuta giustapponendo o concatenando simboli (caratteri) dell'alfabeto.
- Se una stringa ha m simboli (non necessariamente distinti) allora diciamo che ha lunghezza m.



Lunghezza di una Parola o Stringa

- La lunghezza di una stringa w è denotata con |w|.
- Le parole di lunghezza 1 sono i simboli di X.
 - Quindi 001110 è una parola di lunghezza 6

$$|001110| = 6$$

La parola vuota (o stringa vuota), denotata con λ , è una stringa priva di simboli ed ha lunghezza 0

$$|\lambda| = 0$$



- Uguaglianza tra stringhe
 - Due stringhe sono uguali se i loro caratteri, letti ordinatamente da sinistra a destra, coincidono.
- X*
 - L'insieme di tutte le stringhe di lunghezza finita sull'alfabeto X si denota con X*.
- Esempio
 - □ Se $X = \{0,1\}$, allora $X^* = \{\lambda, 0, 1, 00, 01, 10, 11, ...\}$
- X* ha un numero di elementi che è un infinito numerabile.
 - Dalla definizione, segue che $\lambda \in X^*$, per ogni insieme X.



- Concatenazione o prodotto
 - Sia $\alpha \in X^*$ una stringa di lunghezza $m \in \beta \in X^*$ una stringa di lunghezza n, la concatenazione di $\alpha \in \beta$, denotata con $\alpha\beta$ o $\alpha \cdot \beta$, è definita come la stringa di lunghezza m+n, i cui primi m simboli costituiscono una stringa uguale a α ed i cui ultimi n simboli costituiscono una stringa uguale a β .
 - \square Quindi se $\alpha = x_1 x_2 ... x_m$ e $\beta = x_1' x_2' ... x_n'$, si ha:

$$\alpha\beta = x_1 x_2 \dots x_m x_1' x_2' \dots x_n'$$

□ Se X = alfabeto latino

$$\alpha = capo$$
 $\beta = stazione$ $\alpha\beta = capostazione$



Operazione di concatenazione

La concatenazione di stringhe su X è una operazione binaria su X*:

$$\cdot : X^* \times X^* \to X^*$$

- \square è associativa: $(\alpha\beta)\gamma = \alpha(\beta\gamma) = \alpha\beta\gamma$, $\forall \alpha, \beta, \gamma \in X^*$
- □ non è commutativa: $\exists \alpha, \beta \in X^* : \alpha\beta \neq \beta\alpha$
 - capostazione ≠ stazionecapo
- □ ha elemento neutro λ : $\lambda \alpha = \alpha \lambda = \alpha$, $\forall \alpha \in X^*$
- Dunque (X^*, \cdot) è un monoide (non commutativo).



Osservazione

- In base alla definizione di prodotto, ogni parola non vuota α = x₁x₂...x_n si può scrivere in uno ed un solo modo come prodotto di parole di lunghezza 1, cioè di elementi di X.
- Ciò si esprime dicendo che:
 - \square (X^*, \cdot) è il monoide libero generato dall'insieme X.



Prefisso, Suffisso

□ Se $\gamma \in X^*$ è della forma $\gamma = \alpha \beta$, ove $\alpha, \beta \in X^*$, allora α è un *prefisso* di γ e β è un *suffisso* di γ .

Sottostringa

□ Se δ , β ∈ X^* e δ è della forma δ = $\alpha\beta\gamma$, ove α , β ∈ X^* allora β è una sottostringa di δ .

Esempio

Sia γ = 00110. Allora: $\{\lambda, 0, 00, 001, 0011, \gamma\}$ è l'insieme dei prefissi di γ $\{\lambda, 0, 10, 110, 0110, \gamma\}$ è l'insieme dei suffissi di γ $\{\lambda, 0, 1, 00, 01, 10, 11, 001, 011, 110, 0011, 0110, \gamma\}$ è l'insieme delle sottostringhe di γ .



- Potenza di una stringa
 - Data una stringa α su X, la *potenza h*-esima di α è definita (induttivamente) come segue:

$$\alpha^{h} = \begin{cases} \lambda & \text{se } h = 0\\ \alpha \alpha^{h-1} & \text{altrimenti} \end{cases}$$

con h = 0, 1, 2, ...

La potenza h-esima di una stringa è un caso speciale di concatenamento (in quanto la si ottiene concatenando una stringa h volte con se stessa).



Potenza di un alfabeto

- ☐ Sia X un alfabeto, poniamo:
 - 1) $X^1 = X$
 - 2) $X^2 = \{x_1 x_2 \mid x_1, x_2 \in X, x_1 x_2 \equiv x_1 \cdot x_2\}$
 - 3) $X^3 = \{x_1 x_2 x_3 \mid x_1 x_2 \in X^2, x_3 \in X, x_1 x_2 x_3 \equiv x_1 x_2 \cdot x_3 \}$
 - ..)
 - i) $X^{i} = \{x_{1}x_{2}...x_{i-1}x_{i} \mid x_{1}x_{2}...x_{i-1} \in X^{i-1}, x_{i} \in X, x_{1}x_{2}...x_{i} \equiv x_{1}x_{2}...x_{i-1} \cdot x_{i}\}$



- Potenza di un alfabeto
 - Se i ≥ 2 si ha:

$$X^{+} = X \cup X^{2} \cup ... \cup X^{i} \cup ... = \bigcup_{i=1}^{+\infty} X^{i}$$

□ Se λ è la parola vuota e prendiamo un $w \in X^+$ tale che $w \cdot \lambda = \lambda \cdot w = w$ si ha:

$$X^* = {\lambda} \cup X^+$$

Inoltre si ha:

$$X^{h} = \begin{cases} \{\lambda\} & \text{se } h = 0\\ X \cdot X^{h-1} & \text{altrimenti} \end{cases}$$



- Linguaggio formale
 - Un linguaggio formale L su un alfabeto X è un sottoinsieme di X*.

$$L \subseteq X^*$$

- Esempio:
 - Il linguaggio delle parentesi ben formate è un linguaggio formale in quanto, denotato con M tale linguaggio, si ha:

$$M \subset \{(,)\}^*$$

 I linguaggi formali possono essere di natura molto diversa l'uno dall'altro.



Esempi di linguaggi formali

- Un linguaggio di programmazione può essere costruito a partire dall'alfabeto X dei simboli sulla tastiera.
- L'insieme, finito o infinito, dei programmi ben costruiti sintatticamente (ossia, che rispettano la sintassi) costituisce un linguaggio.
- Consideriamo l'insieme dei teoremi di una teoria matematica. I teoremi sono particolari stringhe di simboli del nostro alfabeto. L'insieme dei teoremi "ben formati" rappresenta un linguaggio. Ad esempio, la stringa "ab=ba" non è un teorema della teoria dei gruppi, ma della teoria dei gruppi abeliani.



Generazione e riconoscimento di linguaggi formali

- A noi interessano i linguaggi formali da almeno due punti di vista
 - Descrittivo/Generativo
 - Riconoscitivo



Generazione e riconoscimento di linguaggi formali

Punto di vista Descrittivo/Generativo

Un linguaggio finito può essere descritto/generato per elencazione degli elementi (se il numero non è troppo grande). Un linguaggio infinito non è elencabile. Questi sono i più interessanti perché devono essere specificati necessariamente attraverso una proprietà che ne caratterizza gli elementi, che ne definisce l'intensione. Tale proprietà può essere vista come una regola da seguire per generare gli elementi del linguaggio. Il vero problema è trovare la(e) regola(e) generativa(e) (di produzione) di un linguaggio. È quello che accade quando si impara un linguaggio: non è possibile memorizzare tutte le frasi del linguaggio.



Generazione di linguaggi formali

Esempio

- Non è possibile "elencare" tutti i teoremi della teoria dei gruppi, perché sono infiniti i teoremi realizzabili combinando quelli noti.
- Un libro di teoria dei gruppi non è l'elencazione dei teoremi, ma fornisce una serie di assiomi e le regole con le quali, a partire dagli assiomi, è possibile costruire tutti i teoremi della teoria dei gruppi.
- Per descrivere la regola di produzione di un linguaggio, utilizzeremo una notazione insiemistica.



Generazione di linguaggi formali

Esempio

Sia L il linguaggio su $X = \{0\}$ costituito da tutte e sole le stringhe che hanno un numero pari di 0, cioè:

$$L = \{\lambda, 00, 0000, 000000, ...\}$$

La regola di produzione di *L* viene espressa come segue:

$$L = \{\lambda\} \cup \{w^n \mid w = 00, n = 1, 2, ...\}$$



Generazione e riconoscimento di linguaggi formali

- Punto di vista Riconoscitivo
 - □ Come possiamo *riconoscere* gli elementi di un dato linguaggio *L*? Questo secondo punto di vista ha come obiettivo la costruzione di "macchine" in grado di decidere/stabilire se una stringa è un elemento di *L* oppure no. Si intende costruire una "macchinetta" cui dare in ingresso una particolare parola e che produce una tra due possibili risposte:

$$si \equiv ' \in L'$$
 e $no \equiv ' \notin L'$
 $w = x_1 x_2 \dots x_n$



Riconoscimento di linguaggi formali

Esempio

L'esecuzione di un programma errato sintatticamente viene inibita. Questo è indice dell'esistenza di una "macchinetta" che stabilisce se il programma appartiene o no all'insieme dei programmi sintatticamente ben costruiti.



Generazione di linguaggi formali: esempio

Sia dato l'alfabeto: $X = \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9, +, -\}$ Voglio generare il linguaggio L dei numeri interi relativi. Ovviamente: $L \subseteq X^*$

Più precisamente, $L \subset X^*$ poiché, ad esempio,

$$1++-5 \notin L$$

Non possiamo elencare gli elementi di *L*. Cerchiamo dunque una serie di regole mediante le quali è possibile produrre tutti e soli gli elementi di *L*.

Assumiamo, per semplicità, che un numero relativo sia costituito da una serie di cifre precedute da + o -.



Generazione di linguaggi formali: esempio

Adottiamo la BNF per descrivere le produzioni:

$$< S > ::= + < I > | - < I >$$
 $< I > ::= < D > | < I > < D >$
 $< D > ::= 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9$

- Queste regole generano tutti gli interi relativi purché partiamo dal simbolo nonterminale S.
- □ I è il simbolo nonterminale (da ora in poi, talvolta abbreviato in NT), anche detto categoria sintattica, che sta ad indicare (e da cui si genera) la classe dei numeri interi.
- ☐ I è definito ricorsivamente o come una cifra oppure come un intero seguito da una cifra.
- Ogni intero relativo è generato da queste regole e niente che non sia un intero relativo può essere generato da queste regole.

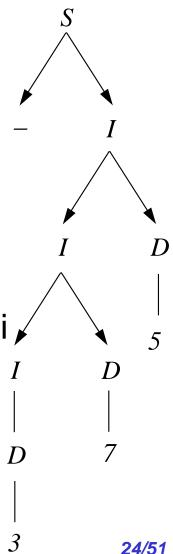
10

Generazione di linguaggi formali: esempio

- Generazione ad albero:
 - proviamo a generare l'intero relativo -375
- Tale albero prende il nome di albero di derivazione.
- $S \Rightarrow -375 \Leftrightarrow -375 \in L$
- Nella notazione vista per il linguaggio delle parentesi ben formate, tipica per i linguaggi formali, la grammatica diventa:

$$S \to +I \mid -I$$

 $I \to D \mid ID$
 $D \to 0 \mid 1 \mid 2 \mid 3 \mid 4 \mid 5 \mid 6 \mid 7 \mid 8 \mid 9$





Grammatiche generative

- Dagli esempi di linguaggi visti, possiamo trarre le seguenti conclusioni. Per generare un linguaggio sono necessari:
 - un insieme X di simboli primitivi con cui si formano le parole del linguaggio, detto *alfabeto dei simboli terminali* o *alfabeto terminale*;
 - un insieme V di simboli ausiliari o variabili con cui si identificano le categorie sintattiche del linguaggio, detto alfabeto dei simboli nonterminali (ausiliari) o alfabeto nonterminale o alfabeto delle variabili;
 - un simbolo speciale *S*, scelto tra i nonterminali, da cui far partire la generazione delle parole del linguaggio. Tale simbolo è detto assioma o scopo o simbolo distintivo o simbolo di partenza o simbolo iniziale;
 - un insieme *P* di produzioni, espresse in un formalismo quali regole di riscrittura, BNF (*a* ::= *b*), carte sintattiche, ...

Definizione di Grammatica generativa o a struttura di frase

 Una grammatica generativa o a struttura di frase G è una quadrupla

$$G = (X, V, S, P)$$

ove:

- Vè l'alfabeto nonterminale o delle variabili per la grammatica;
- Sè il simbolo di partenza per la grammatica;
- □ Pè l'insieme delle *produzioni* della grammatica ed inoltre valgono le seguenti condizioni:

$$X \cap V = \emptyset$$
 e $S \in V$



Definizione di Produzione

Una produzione è una coppia (v, w),

ove $v \in (X \cup V)^+$ e v contiene un $NT \Leftrightarrow v \in (X \cup V)^*V(X \cup V)^*$ $w \in (X \cup V)^*$ (w può essere anche λ).

Un elemento (v,w) di P viene comunemente scritto nella forma:

$$v \rightarrow w$$

Una produzione deve, in qualche modo, riscrivere un NT.



Definizione di Produzione

- Per convenzione, gli elementi di X sono rappresentati di solito con lettere minuscole (con o senza pedici e di solito sono le prime lettere dell'alfabeto) o cifre ed operatori (connettivi), mentre gli elementi di V sono rappresentati con lettere maiuscole (con o senza pedici) o con stringhe delimitate dalle parentesi angolari "<" e ">".
- La notazione $\alpha \rightarrow \beta_1 \mid \beta_2 \mid ... \mid \beta_k$ è impiegata come abbreviazione della seguente:

$$\alpha \rightarrow \beta_1$$
 $\alpha \rightarrow \beta_2$
...

$$\alpha \rightarrow \beta_k$$



Esempi di grammatiche

 La grammatica per il linguaggio delle parentesi ben formate

$$G_1 = \{ \{ (,) \}, \{S\}, S, \{S \to (), S \to (S), S \to SS \} \}$$

 La grammatica per il linguaggio dei numeri interi relativi

$$G_2 = (\{0, 1, 2, 3, 4, 5, 6, 7, 8, 9, +, -\}, \{S, I, D\}, S,$$

 $\{S \to +I, S \to -I, I \to D, I \to ID, D \to 0, D \to 1, ..., D \to 9\})$



Definizione di derivazione o produzione diretta

Sia G = (X, V, S, P) una grammatica e siano $y \in Z$ due stringhe finite di simboli in $X \cup V$ (stringhe di terminali e nonterminali) tali che:

$$y = \gamma \alpha \delta$$
 e $z = \gamma \beta \delta$, ove $y \in (X \cup V)^+$, $z \in (X \cup V)^*$, $\beta, \gamma, \delta \in (X \cup V)^*$ $\alpha \in (X \cup V)^+$ e α contieneum NT

1) Scriviamo

$$y \Longrightarrow z$$

e diciamo che *y produce direttamente z* o che *z* è derivata direttamente da *y* se:

$$\alpha \rightarrow \beta \in P$$

ossia se esiste in G una produzione $\alpha \rightarrow \beta$



Definizione di derivazione o produzione diretta

2) Scriviamo

$$y \stackrel{*}{\Longrightarrow} z$$

e diciamo che *y produce z* o che *z è derivabile da y* se y = z o esiste una sequenza di stringhe $w_1, w_2, ..., w_n$, con $w_1, w_2, ..., w_{n-1} \in (X \cup V)^+$, $w_n \in (X \cup V)^*$ $w_1 = y$ e $w_n = z$ tali che $\forall i, i = 1, 2, ..., n-1 : w_i \Rightarrow w_{i+1}$ (w_i produce direttamente w_{i+1}), cioè:

$$y \Rightarrow z \Leftrightarrow \begin{cases} y = z \\ \text{oppure} \\ w_1 = y \Rightarrow w_2 \Rightarrow w_3 \Rightarrow \dots \Rightarrow w_{n-1} \Rightarrow w_n = z \end{cases}$$



Osservazione

La nozione di derivazione diretta stabilisce una relazione binaria in (X ∪ V)*.
Date due stringhe y e z, il simbolo ⇒ può esserci o meno; dipende dall'esistenza di una produzione.
Allora possiamo anche definire una composizione di relazioni:

$$y \stackrel{2}{\Rightarrow} z \iff \exists w : y \implies w \in w \implies z$$

dove 2 è il numero di trascrizioni necessarie per passare da *y* a *z* (ossia, la *lunghezza della derivazione*).

Osservazione

■ Da ciò si ha: $\stackrel{*}{\Rightarrow} = I \cup \Rightarrow \cup \stackrel{?}{\Rightarrow} \cup \stackrel{3}{\Rightarrow} \cup \dots$

ove l è la relazione identica e \Rightarrow indica la composizione della relazione \Rightarrow n volte con se stessa.

*

è la chiusura riflessiva e transitiva della relazione di derivazione diretta;

+

è la chiusura transitiva della stessa relazione.

Definizione di linguaggio generato da una grammatica

Sia G = (X, V, S, P) una grammatica. Il linguaggio generato da G, denotato con L(G), è l'insieme delle stringhe di terminali derivabili dal simbolo di partenza S.

$$L(G) = \left\{ w \in X^* \mid S \underset{G}{\Longrightarrow} w \right\}$$

- Sono, dunque, stringhe di L(G) le stringhe che:
 - consistono di soli terminali;
 - possono essere derivate da S in G.



Definizione di forma di frase

Sia G = (X, V, S, P) una grammatica. Una stringa w, $w \in (X \cup V)^*$, è una forma di frase di G se:

$$S \stackrel{*}{\Longrightarrow} W$$

- Alle forme di frase si applicano le stesse definizioni (es.: potenza) e gli stessi operatori (es.: concatenazione) dati per le stringhe.
- Proposizione:
 - Data una grammatica G = (X, V, S, P), L(G) è l'insieme delle forme di frase terminali (o frasi) di G.



Definizione di grammatiche equivalenti

 Due grammatiche G e G' si dicono equivalenti se generano lo stesso linguaggio, ossia se

$$L(G)=L(G')$$

Sia G = (X, V, S, P), ove

$$X = \{a,b\}, \qquad V = \{S\}, \qquad P = \left\{S \xrightarrow{(1)} aSb, S \xrightarrow{(2)} ab\right\}$$

Determiniamo L(G).

$$ab \in L(G)$$
 poiché $S \Longrightarrow ab$

 $ab \in L(G)$ poiché $S \Longrightarrow ab$ Se numeriamo le produzioni, possiamo indicare la produzione usata immediatamente al di sotto del $simbolo \Rightarrow$.

$$\Rightarrow$$
 = ho applicato la produzione n

$$y \Rightarrow z \equiv y$$
 produce z in k passi, dove k=lunghezza della derivazione



■
$$a^2b^2 \in L(G)$$
 poiché $S \Rightarrow aSb \Rightarrow a^2b^2$

■
$$a^3b^3 \in L(G)$$
 poiché $S \Rightarrow a^3b^3$

.

$${a^nb^n \mid n > 0} \subseteq L(G)$$

- Inoltre, qualsiasi derivazione da S in G produce frasi del tipo aⁿbⁿ.
 - \square Dunque $L(G) \subseteq \{a^n b^n \mid n > 0\}$ e quindi

$$L(G) = \{a^n b^n \mid n > 0\}$$



Notazione

- Per rendere più concisa la descrizione di una grammatica, spesso ci limiteremo ad elencarne le produzioni, quando sia chiaro quale sia il simbolo di partenza e quali siano i terminali ed i nonterminali.
- Inoltre, le produzioni con la stessa parte sinistra vengono accorpate attraverso l'uso del simbolo " | " (preso a prestito dalla BNF).
- Infine, ometteremo l'indicazione della grammatica dalla simbologia di derivazione e derivazione diretta quando sia chiaro dal contesto a quale grammatica si fa riferimento.

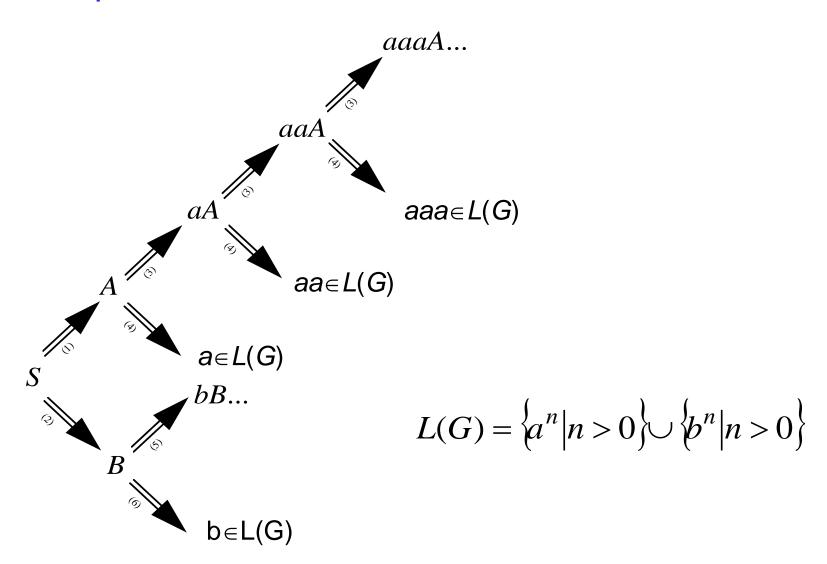


Sia data la seguente grammatica: (5) (6)
$$S \rightarrow A \mid B, \quad A \rightarrow aA \mid a, \quad B \rightarrow bB \mid b$$

Determinare L(G).

Non sappiamo se applicare $S \rightarrow A$ oppure $S \rightarrow B$ inizialmente. I meccanismi di costruzione di un linguaggio sono generalmente non deterministici, poiché può non essere univoca la sostituzione da operare ad una forma di frase se uno stesso NT si trova a sinistra di 2 o più produzioni, come illustrato nella figura seguente.







- Dunque, una grammatica è uno strumento generativo di un linguaggio perché, data una qualsiasi parola di quel linguaggio, possiamo risalire mediante le produzioni al simbolo di partenza della grammatica.
- Viceversa, dato il simbolo di partenza di una grammatica, seguendo uno qualsiasi dei cammini dell'albero di derivazione, si produce una parola "valida" del linguaggio.



- In generale, dato un linguaggio L ed una grammatica G, non esiste un algoritmo in grado di dimostrare che la grammatica genera il linguaggio, ossia che L = L(G).
 - Più specificamente, <u>non</u> esiste un algoritmo che stabilisce se una data stringa è generata o no dalla grammatica presa in considerazione.
- Tutto ciò si riassume nella seguente proposizione:
 - Il problema di dimostrare la correttezza di una grammatica non è risolubile algoritmicamente, in generale.



- In molti casi importanti, però, è possibile dimostrare per induzione che una particolare grammatica genera proprio un particolare linguaggio.
- Queste dimostrazioni ci consentono di stabilire se, data una grammatica G ed un linguaggio L, risulta:
 - \square $w \in L(G) \Rightarrow w \in L$ cioè $L(G) \subseteq L$
 - \square $w \in L \implies w \in L(G)$ cioè $L \subseteq L(G)$



- In molti casi importanti, però, è possibile dimostrare per induzione che una particolare grammatica genera proprio un particolare linguaggio.
- Queste dimostrazioni ci consentono di stabilire se, data una grammatica G ed un linguaggio L, risulta:

$$\square$$
 $w \in L(G) \Rightarrow w \in L$ cioè $L(G) \subseteq L$

$$\square$$
 $w \in L \implies w \in L(G)$ cioè $L \subseteq L(G)$

La grammatica *G* genera solo stringhe appartenenti al linguaggio *L*.



- In molti casi importanti, però, è possibile dimostrare per induzione che una particolare grammatica genera proprio un particolare linguaggio.
- Queste dimostrazioni ci consentono di stabilire se, data una grammatica G ed un linguaggio L, risulta:
 - \square $w \in L(G) \Rightarrow w \in L$ cioè $L(G) \subseteq L$
 - \square $w \in L \implies w \in L(G)$ cioè $L \subseteq L(G)$

Il linguaggio *L* comprende solo parole generabili dalla grammatica *G*.



Principio di induzione

- Sia n_0 un intero e sia P=P(n) un enunciato che ha senso per ogni intero maggiore o uguale ad n_0 . Se:
 - \square $P(n_0)$ è vero
 - □ Per ogni $n>n_0$, P(n-1) vero implica P(n) vero allora P(n) è vero per tutti gli n maggiori o uguali ad n_0



Determinare una grammatica che genera il seguente linguaggio:

$$L = \{a^n b^n \mid n > 0\}$$

e dimostrare questo risultato.

Che tipo di grammatica genera L?



Determinare una grammatica che genera il seguente linguaggio:

$$L = \{a^n b^{2n} \mid n > 0\}$$

e dimostrare questo risultato.

Di che tipo è la grammatica che genera L?



Sia data la seguente grammatica:

Determinare il linguaggio generato da G.



Dimostrare per induzione che il linguaggio L generato dalla seguente grammatica è vuoto:

$$G = (X, V, S, P)$$

$$X = \{a, b, c\} \qquad V = \{S, A, B\}$$

$$P = \left\{S \rightarrow aBS \mid bA, aB \rightarrow Ac \mid a, bA \rightarrow S \mid Ba\right\}$$
Soluzione escercizio