

I metodi formali dell'Analisi Lessicale: Le Espressioni Regolari (ER)

N.Fanizzi - V.Carofiglio

6 aprile 2016

- 1 Introduzione
- 2 Definizioni
- 3 Corrispondenza Linguaggi - Espressioni Regolari
- 4 Proprietà dei Linguaggi Regolari
- 5 Esercizi

Espressioni Regolari

Dato un alfabeto finito X , una espressione regolare è una notazione per descrivere linguaggi regolari sull'alfabeto ampliato

$X \cup \{\lambda, +, *, \cdot, \emptyset, (,)\}$:

ESEMPI

- $L = \{a\} \quad R(L) = a$
- $L = \{a, b, c\} \quad R(L) = a + b + c$
(+ denota UNIONE tra linguaggi)
- $L = (\{a\} \cup \{bc\})^* \quad R(L) = (a + b \cdot c)$
(* e \cdot denotano ITERAZIONE e CONCATENAZIONE tra linguaggi)

Espressioni Regolari - definizione

Dato un alfabeto finito X , una stringa R sull'alfabeto ampliato $X \cup \{\lambda, +, *, \cdot, \emptyset, (,)\}$ è una **espressione regolare** di alfabeto X se vale una delle seguenti condizioni:

- $R = \emptyset$
- $R = \lambda$
- $R = a$ con $a \in X$
- $R = (R_1 + R_2)$ con R_1, R_2 espressioni regolari di alfabeto X
- $R = (R_1 \cdot R_2)$ con R_1, R_2 espressioni regolari di alfabeto X
- $R = (R_1)^*$ con R_1 espressione regolare di alfabeto X

L'insieme delle espressioni regolari di alfabeto X viene denotato con \mathcal{R}

Linguaggi Regolari

Dato un alfabeto finito X

un linguaggio L su X è un **linguaggio regolare** sse:

- L è finito
oppure
- L può essere ottenuto induttivamente mediante le operazioni:
 - 1 $L = L_1 \cup L_2$ con L_1, L_2 regolari
 - 2 $L = L_1 \cdot L_2$ con L_1, L_2 regolari
 - 3 $L = L_1^*$ con L_1 regolare

Osservazione: \emptyset e $\{\lambda\}$ sono linguaggi regolari

Definiamo l'insieme di tali linguaggi come **classe dei linguaggi regolari** denotata con \mathcal{L}_{REG}

Operazioni sui linguaggi (Dovere di cronaca)

Dati due linguaggi L e L' definiti sullo stesso alfabeto X :

unione $L \cup L' = \{w \in X^* \mid w \in L \vee w \in L'\}$

prodotto $L \cdot L' = \{w = w_1 \cdot w_2 \in X^* \mid w_1 \in L \wedge w_2 \in L'\}$

iterazione $L^* = \{w_1 \dots w_n \in X^* \mid \forall n \forall i: w_i \in L, 0 \leq i \leq n\}$

complemento $\bar{L} = \{w \in X^* \mid w \notin L\}$

intersezione $L \cap L' = \{w \in X^* \mid w \in L \wedge w \in L'\}$

potenza $L^k = \begin{cases} \{\lambda\} & k=0 \\ L^{k-1} \cdot L & k>0 \end{cases}$

chiusura (transitiva) $L^+ = \bigcup_{k>0} L^k$
(quindi si può scrivere $L^* = L^0 \cup L^+ = \{\lambda\} \cup L^+$)

Esempi.

Dati i linguaggi $L_1 = \{a^{2n} \mid n \geq 0\}$ e $L_2 = \{b, cc\}$

- $L_1 \cdot L_2 = \{b, cc, aab, aacc, aaaab, aaaacc, \dots\}$
- $L_2 \cdot L_1 = \{b, cc, baa, ccaa, baaaa, ccaaaa, \dots\}$
- $L_1 \cup L_2 = L_2 \cup L_1 = \{\lambda, b, cc, aa, aaaa, aaaaaa, \dots\}$
- $L_1^* = \{\lambda, aa, aaaa, aaaaaa, aaaaaaaa, \dots\}$
- $L_2^* = \{\lambda, b, cc, bb, bcc, ccb, bbb, cccc, \dots\}$
- $L_2^0 = \{\lambda\}$
 $L_2^1 = \{b, cc\}$
 $L_2^2 = \{bb, bcc, ccb, cccc\} \dots$
- $L_2^+ = \{b, cc, bb, bcc, ccb, bbb, cccc, \dots\}$

Corrispondenza Linguaggi - Espressioni Regolari

Ad ogni espressione regolare R
corrisponde un linguaggio regolare $S(R)$:

espressione regolare	linguaggio regolare
\emptyset	\emptyset
λ	$\{\lambda\}$
a	$\{a\}$
$(R_1 + R_2)$	$S(R_1) \cup S(R_2)$
$(R_1 \cdot R_2)$	$S(R_1) \cdot S(R_2)$
$(R)^*$	$(S(R))^*$

Proposizione.

Un linguaggio su X è regolare sse esso corrisponde ad una espressione regolare di alfabeto X
ossia definita la funzione $S : \mathcal{R} \longrightarrow \wp(X^*)$, si ha che:

$$\mathcal{L}_{REG} = \{L \in \wp(X^*) \mid \exists R \in \mathcal{R}: L = S(R)\}$$

Osservazioni.

- un linguaggio regolare può essere descritto da più di una espressione regolare, cioè
- la funzione S non è inettiva

Due **espressioni regolari** R_1 e R_2 si dicono **equivalenti**,
e si scrive $R_1 = R_2$, sse

$$S(R_1) = S(R_2)$$

Esempio.

L linguaggio delle parole su $X = \{a, b\}$ con a e b alternate, inizianti e terminanti con b

L descrivibile attraverso l'espressione

$$R_1 = b(ab)^*$$

ovvero con

$$R_2 = (ba)^*b$$

pertanto $R_1 = R_2$

1.	$(R_1 + R_2) + R_3 = R_1 + (R_2 + R_3)$	prop. associativa di +
2.	$R_1 + R_2 = R_2 + R_1$	prop. commutativa di +
3.	$R + \emptyset = \emptyset + R = R$	\emptyset elem. neutro per +
4.	$R + R = R$	Idempotenza
5.	$(R_1 \cdot R_2) \cdot R_3 = R_1 \cdot (R_2 \cdot R_3)$	prop. associativa di ·
6.	$R_1 \cdot R_2 \neq R_2 \cdot R_1$	non commutatività di ·
7.	$R \cdot \lambda = \lambda \cdot R = R$	λ elem. neutro per ·
8.	$R \cdot \emptyset = \emptyset \cdot R = \emptyset$	\emptyset elem. assorbente per ·
9.	$R_1 \cdot (R_2 + R_3) = (R_1 \cdot R_2) + (R_1 \cdot R_3)$	prop. distributiva di · risp. a +
10.	$(R_1 + R_2) \cdot R_3 = (R_1 \cdot R_3) + (R_2 \cdot R_3)$	prop. distributiva di · risp. a +
11.	$(R)^* = (R)^* \cdot (R)^* = ((R)^*)^* = (\lambda + R)^*$	
12.	$(\emptyset)^* = (\lambda)^* = \lambda$	
13.	$(R)^* = \lambda + R + \dots + R^n + (R^{n+1} \cdot R^*)$	
14.	$(R_1 + R_2)^* = (R_1^* + R_2^*)^* = (R_1^* \cdot R_2^*)^* =$ $= (R_1^* \cdot R_2^*)^* \cdot R_1^* = R_1^* \cdot (R_1^* \cdot R_2^*)^*$	
15.	$(R_1 + R_2)^* \neq R_1^* + R_2^*$	in generale
16.	$R \cdot R^* = R^* \cdot R$	
17.	$R_1 \cdot (R_2 \cdot R_1)^* = (R_1 \cdot R_2)^* \cdot R_1$	
18.	$(R_1^* \cdot R_2)^* = \lambda + (R_1 + R_2)^* \cdot R_2$	
19.	$(R_1 \cdot R_2^*)^* = \lambda + R_1 \cdot (R_1 + R_2)^*$	
20.	$R_1 = R_2 \cdot R_1 + R_3$ sse $R_1 = R_2^* \cdot R_3$ $R_1 = R_1 \cdot R_2 + R_3$ sse $R_1 = R_3 \cdot R_2^*$	con $R_2 \neq \lambda$

Esercizi

- ❶ Data l'espressione $R = a^* \cdot (a + b)$, trovare il linguaggio associato.
- ❷ Data L'espressione $R = (aa)^*(bb)^*b$, trovare il linguaggio associato
- ❸ Data l'espressione $R = (a + b)^*(a + bb)$, trovare il linguaggio associato
- ❹ Fissato l'alfabeto $X = \{0, 1\}$ dare l'espressione regolare R , tale che:
 - $S(R) = \{w \in X^* \mid w \text{ ha almeno una coppia di } 0 \text{ consecutivi}\}$
 - $S(R) = \{w \in X^* \mid w \text{ non ha coppie di } 0 \text{ consecutivi}\}$
- ❺ Trovare tutte le stringhe di lunghezza minore di quattro in $S((a + b)^*b(a + ab)^*)$
- ❻ Trovare l'espressione regolare per:
 - $L = \{a^n b^m \mid (n + m) \text{ pari}\}$
 - $L = \{a^n b^m \mid n \geq 4; m \geq 3\}$

Esercizi

- 1 Scrivere le espressioni regolari per i seguenti linguaggi su $X = \{0, 1\}$
- tutte le stringhe che terminano per 01
 - tutte le stringhe che non terminano per 01
 - tutte le stringhe contenenti un numero pari di 0
 - tutte le stringhe che hanno almeno due occorrenze di sottostringhe 00 (nota che 000 contiene due occorrenze di 00)
 - tutte le stringhe che hanno al più due occorrenze di sottostringhe 00
 - tutte le stringhe che non contengono occorrenze di 101

Esercizi

- ❶ Trovare le espressioni regolari per i seguenti linguaggi su $\{a, b\}$
- $L = \{w \mid |w| \bmod 3 = 0\}$
 - $L = \{w \mid n_a(w) \bmod 3 = 0\}$
 - $L = \{w \mid n_a(w) \bmod 5 < 0\}$

Esercizio1

Individuare il linguaggio $S(a^* \cdot (a + b))$

$$\begin{aligned} S(a^* \cdot (a + b)) &= \\ S(a^*) \cdot S(a + b) &= \\ (S(a))^* \cdot (S(a) \cup S(b)) &= \\ \{ \lambda, a, aa, aaa, \dots \} \cdot \{ a, b \} &= \\ \{ \lambda, a, aa, aaa, \dots, b, ab, aab, \dots \} \end{aligned}$$

Esercizio2

Individuare il linguaggio $S((a + b)^*(a + bb))$

$(a + b)^*$ stringhe di "a" e "b"

$(a + bb)$ stringa "a" oppure stringa "bb"

$S((a + b)^*(a + bb))$ é l'insieme su $\{a, b\}$ di stringhe che terminano per "a" oppure per "bb".

ovvero:

$$S((a + b)^*(a + bb)) = \{a, bb, aa, abb, ba, bbb, \dots\}$$

Esercizio3

Individuare il linguaggio $S((aa)^*(bb)^*b)$

$$S((aa)^*(bb)^*b) = \{a^{2n}b^{2m+1} \mid n \geq 0, m \geq 0\}$$

Esercizio4a

Individuare l'espressione regolare per il linguaggio su $X\{0,1\}$

$$L = \{w \in X^* \mid w \text{ ha almeno una coppia di zeri consecutivi}\}$$

Ogni stringa di L deve contenere:

- almeno un "00"
- ed é del tipo "x00y", con x e y arbitrarie stringhe su X^* $((0+1)^*)$

dunque $L = S((0+1)^* 00 (0+1)^*)$

Esercizio4b

Individuare l'espressione regolare per il linguaggio

$$L = \{w \in \{0, 1\}^* \mid w \text{ NON ha coppie di zeri consecutivi}\}$$

Osserviamo che

- se occorre uno "0", subito dopo ci deve essere un "1"
- la sotto-stringa "01" può essere preceduta e seguita da "1"

Dunque:

La risposta contiene ripetiz. di "1...101...1" (ovvero $(1^*(01)1^*)^*$)

- mancano le stringhe del tipo "1...101...10" ($(1^*(01)1^*0)$)

Dunque:

La risposta contiene anche ripetizioni di stringhe della forma "1...101...10" (ovvero $(1^*(01)1^*)^* (0 + 0)$)

- mancano le stringhe del tipo "1...10" ((1^*0))
- mancano le stringhe del tipo "1...1" ((1^*))

dunque mancano $1^*(0 + \lambda)$

dunque

$$L = S((1^*(01)1^*)^* (0 + \lambda) + (1^*(0 + \lambda)))$$

Esercizio4b-bis

Individuare l'espressione regolare per il linguaggio

$$L = \{w \in \{0,1\}^* \mid w \text{ NON ha coppie di zeri consecutivi}\}$$

- $S((1^*(01)1^*)^* (0 + \lambda) + (1^*(0 + \lambda)))$
- $S((1 + (01))^* (0 + \lambda))$

definiscono lo stesso linguaggio?